

Skill Lab 1

Análisis y selección de modelos para un caso de negocio

Instituto Tecnológico y de Estudios Superiores de Monterrey
Maestría en Inteligencia Artificial Aplicada

Materia: Sistemas multiagente (IA5004.10)

Actividad: Skill Lab 1 — Análisis y selección de modelos para un caso de negocio

Conjunto de datos: conjunto común LAB1-A (modo precargado)

Alumno: Oscar Alberto Ramírez Anaya

Matrícula: A01795438

Correo: A01795438@tec.mx

Fecha de entrega: 4 de octubre de 2026

Contenido

1. Resumen ejecutivo	2
2. Contexto, datos y método	2
3. Sección A. Tokens y costo	3
4. Sección B. Efecto de posición	4
5. Sección C. Evaluación comparativa con criterio previo	5
6. Sección D. Model Decision Cards	7
7. Conclusiones y recomendación de negocio	8

1. Resumen ejecutivo

Para la **consulta de campo** recomiendo el modelo **rápido** como decisión provisional: es el único que cumple la latencia de 2.0 s (1.4 s), pero con 13/20 aciertos no alcanza el umbral de 15/20 que fijé antes de ver los resultados, por lo que se usa como asistente sugerido y bajo vigilancia. Para el **resumen nocturno** recomiendo el modelo **capaz**, que cumple el criterio (18/20 aciertos) y cuya latencia de 6.3 s no importa en lote. El catálogo (1580 tokens) no debe entrar completo a cada consulta, y la evidencia decisiva debe ir al inicio o al final del contexto: enterrarla en medio cuesta 19 % de desempeño.

2. Contexto, datos y método

Distribuidora Cuauhtémoc evalúa un asistente agéntico de inteligencia comercial para dos tareas con perfiles opuestos:

Tarea	Quién la usa	Cuándo	Qué exige
Consulta de campo	El preventista frente a la tienda	En vivo, cientos de veces al día	Respuesta en segundos, costo bajo por llamada, errores tolerables (el humano está ahí)
Resumen nocturno de incidentes	El gerente comercial	Una corrida por noche, en lote	Máxima calidad de síntesis; la latencia no importa; un error llega al comité sin filtro

Datos. Conjunto común LAB1–A del archivo `skill_lab1_variants.json`: conteos didácticos de tokens de tres textos, razón español/inglés, puntuaciones por posición de la evidencia y resultados agregados simulados de dos modelos ("rápido" y "capaz") en 20 casos. No se ejecutan modelos ni se llama a una API; todas las cifras son simuladas.

Método. (1) Calcular el costo de entrada por llamada y por día con las tarifas didácticas; (2) medir la caída de desempeño por posición; (3) escribir y registrar el criterio de aceptación **antes** de consultar la comparación de modelos; (4) aplicar el criterio sin modificarlo y documentar la decisión en una Model Decision Card por tarea. El análisis se hizo en pandas y matplotlib con el notebook del laboratorio.


3. Sección A. Tokens y costo

Resultados

Conteos didácticos del conjunto común y costo de entrada con las tarifas de referencia (rápido 0.15 USD y capaz 1.25 USD por millón de tokens), 1000 llamadas por día.

Texto	Tokens	USD/llamada rápido	USD/día rápido	USD/llamada capaz	USD/día capaz
consulta_campo	47	0.00000705	0.00705	0.00005875	0.05875
reporte_incidentes	449	0.00006735	0.06735	0.00056125	0.56125
catalogo	1580	0.00023700	0.23700	0.00197500	1.97500

Cálculo: USD/llamada = tokens x tarifa / 1,000,000; USD/día = USD/llamada x 1000. Ejemplo: 1580 x 1.25 / 1,000,000 = 0.001975 USD por llamada, 1.975 USD por día.



Razón español/inglés: 1.32. La demostración de contar_tokens dio es=20 y en=16 (razón 1.25), pero es una **estimación** de 4 caracteres por token, no una tokenización real; no la uso para costos. Los cálculos usan los conteos didácticos.

Decisión de mesa

TEXTO_QUE_NO_ENTRA_COMPLETO	catalogo
POR_QUE	El catálogo pesa 1580 tokens, 33.6 veces la consulta de campo (47 tokens): completo en cada una de las 1000 llamadas diarias costaría 1.975 USD/día solo de entrada con el capaz (0.237 USD/día con el rápido), contra 0.059 y 0.007 USD/día de la consulta. De esos 1580 tokens el preventista solo necesita los renglones del SKU y la tienda que consulta; el resto es ruido que encarece cada llamada y empuja la evidencia útil hacia el medio de la ventana (sección B), así que se recuperan solo los renglones pertinentes.

Interpretación


- **El costo escala con lo que se manda, no con lo que se pregunta.** La pregunta del preventista cuesta 0.007 USD al día con el rápido; meter el catálogo completo multiplica la entrada por 34.6 ($47 + 1580 = 1627$ tokens por llamada). Con el capaz, solo el catálogo suma 1.975 USD/día; en un año son unos 721 USD de entrada por un texto que casi nunca se usa completo.
- **Estas cifras son solo de entrada.** No incluyen tokens de salida, instrucciones del sistema ni historial, así que son un piso, no el costo de operación.
- **El idioma es un dato de presupuesto.** Con razón 1.32, el mismo contenido en español cuesta 32 % más tokens que en inglés. Un presupuesto armado con conteos en inglés quedaría corto en la misma proporción.
- **El reporte de incidentes (449 tokens) sí puede entrar completo** al resumen nocturno: es una corrida por noche y cuesta 0.00056 USD de entrada con el capaz.

4. Sección B. Efecto de posición

Resultados

Posición de la evidencia	inicio	medio	final
Puntuación (0-1)	0.86	0.71	0.88

Caída relativa = $(\text{máximo} - \text{medio}) / \text{máximo} = (0.88 - 0.71) / 0.88 = 0.193$, es decir **19 %** del máximo. Frente al inicio la caída es $(0.86 - 0.71) / 0.86 = 17 \%$. Entre inicio y final la diferencia es de solo 0.02.



Interpretación: qué implica para el paquete de contexto del agente

- **El orden es una decisión de ingeniería.** La misma evidencia vale 0.88 al final y 0.71 en medio. En la consulta de campo el paquete debe llevar la pregunta del preventista y los renglones recuperados del SKU al inicio o al final, y nunca entre bloques de relleno.
- **Más contexto puede rendir menos.** Esto conecta con la sección A: si el catálogo de 1580 tokens se mete completo, el renglón relevante queda casi siempre en medio. Se paga 1.975 USD/día de más con el capaz y además se pierde hasta 19 % de desempeño. Recuperar solo lo pertinente ahorra dinero y calidad a la vez.

- **Es una mejora gratis.** Recuperar el 19 % no exige cambiar de modelo ni pagar un token más; solo ordenar bien.
- **En el resumen nocturno** el reporte de 449 tokens se procesa completo; los incidentes graves deben ir al principio o repetirse al final en lugar de quedar en el orden en que llegaron.
- **Límite:** son puntuaciones didácticas de tres posiciones, sin casos ni salidas. No prueban que nuestro sistema pierda 19 %; para afirmarlo hay que medir con casos reales del asistente.

5. Sección C. Evaluación comparativa con criterio previo

Criterio de aceptación (registrado antes de abrir los resultados)


Consulta de campo: se acepta un modelo solo si (1) su latencia media es ≤ 2.0 s (requisito duro: el preventista no espera más frente al tendero), (2) acierta al menos 15/20 casos (tasa ≥ 75 %), entendiendo por acierto que la respuesta cita la cifra correcta del dataset (precio, inventario o SKU) y no inventa promociones; (3) si ambos cumplen, se elige el de menor USD por acierto. Si ninguno cumple, no se acepta ninguno y se documenta.

Resumen nocturno: la latencia no es requisito; se elige el modelo con más aciertos sobre 20 casos (mínimo 15/20 para aceptarlo) y, solo en empate, el de menor USD por acierto.

El criterio se registró en registrar_criterio y comprobar_criterio no detectó cambios al ejecutar evaluar.

Resultados

Modelo	Aciertos	Tasa	Costo total (USD, 20 casos)	USD por acierto	USD por caso	Latencia media (s)
rápido	13/20	0.65	1.09	0.0838	0.0545	1.4
capaz	18/20	0.90	7.12	0.3956	0.3560	6.3



Aplicación del criterio

Condición	rápido	capaz
Campo: latencia ≤ 2.0 s	Cumple (1.4 s)	No cumple (6.3 s, 3.15 veces la tolerancia)
Campo: aciertos $\geq 15/20$	No cumple (13/20)	Cumple (18/20)
Campo: resultado	Ninguno se acepta. Se documenta y no se reescribe el criterio (ver card de campo).	
Nocturno: más aciertos y $\geq 15/20$	13/20, no cumple el mínimo	18/20, se acepta

Cómo leo esta evidencia

- **Aquí pagar más no sale más barato por resultado.** El capaz cuesta 6.5 veces más en total (7.12 contra 1.09 USD) y 4.7 veces más por acierto (0.396 contra 0.084 USD). Aunque acierta 5 casos más, no compensa su precio en costo por resultado.
- **La latencia es requisito, no desempate.** En campo, el 90 % de acierto del capaz no sirve si el preventista espera 6.3 s frente al tendero. En lote, esa misma latencia es irrelevante.
- **El rápido falla 7 de cada 20 consultas.** A 1000 consultas diarias son del orden de 350 respuestas erróneas por día; el capaz serían unas 100. Por eso en campo el humano tiene que verificar.

Límites del criterio: qué se puede contrastar y qué no

- **Sí se contrasta con los agregados:** el umbral de latencia (latencia_media), el umbral de 15/20 (aciertos) y el desempate por USD por acierto (costo_total / aciertos).
- **No se puede contrastar:** la definición de acierto ("cita la cifra correcta y no inventa promociones"). Los aciertos vienen precargados y no sé con qué regla se calificaron; cambiar mi criterio no cambia la tabla. Para verificarlo necesitaría las 20 salidas individuales, las respuestas de referencia y una regla de calificación ejecutable.
- **Latencia media, no percentil.** Un promedio de 1.4 s puede esconder colas de 3 o 4 s; para un requisito de campo haría falta el p95.
- **Muestra pequeña.** Con 20 casos, el intervalo de Wilson al 95 % para 13/20 va de 0.43 a 0.82 y para 18/20 de 0.70 a 0.97. El rápido podría estar por arriba del umbral de 0.75 o muy por debajo, así que 20 casos no bastan para cerrar la decisión de campo.
- **Tarea distinta.** Los 20 casos son de la tarea de campo. Usarlos para el resumen nocturno es una extrapolación que debo validar con casos de síntesis.
- **Escalas de costo distintas.** El costo simulado de la evaluación (0.0545 USD por caso del rápido) no se reconcilia con el costo de entrada de la sección A (0.000007 USD por consulta de 47 tokens). Probablemente incluye contexto y salida, pero el paquete no lo documenta, así que no mezclo las dos cifras en un solo cálculo.

Experimento contrafactual

Con la tabla enfrente es fácil fabricar un criterio a la medida. Quien prefiriera el capaz habría escrito "máximo número de aciertos" y omitido la latencia; quien prefiriera el rápido, "menor costo" y omitido el umbral de aciertos. Cualquiera de los dos "gana" con un criterio elegido después. Con el criterio previo el

resultado incómodo queda a la vista: en campo ninguno cumple, y esa es la información útil para la dirección.

6. Sección D. Model Decision Cards

Card 1. Consulta de campo (síncrona, alto volumen)

Decisión	rápido (provisional)
Justificación	Decisión provisional: ningún modelo cumple el criterio previo. El rápido es el único que respeta el requisito duro de latencia (1.4 s contra 6.3 s del capaz, tolerancia 2.0 s), pero sus 13/20 aciertos (65 %) quedan debajo del umbral de 15/20. El capaz (18/20 aciertos) queda descartado por latencia, y además cuesta 0.396 USD por acierto contra 0.084 USD del rápido (4.7 veces más). En campo el humano está presente y el error es tolerable; por eso se adopta el rápido como asistente sugerido, no como respuesta autónoma, sin reescribir el criterio.
Riesgo residual	Con 65 % de acierto, de 1000 consultas diarias cerca de 350 podrían traer una cifra equivocada (precio, inventario o promoción). Si el preventista confía sin verificar, el error llega al pedido y al tendero. Los agregados tampoco permiten saber si los errores son cifras inventadas u omisiones.
Mitigación	Respuesta siempre con la cifra y su fuente (SKU y renglón del catálogo) para que el preventista la confirme; contexto acotado a los renglones pertinentes con la evidencia al inicio o al final. Muestreo semanal de 20 casos calificados contra el criterio; si en 4 semanas no se alcanzan 15/20 aciertos, revisar el contexto o evaluar un modelo intermedio que cumpla 2.0 s. Monitoreo diario de latencia (alerta si la media pasa de 2.0 s).

Card 2. Resumen nocturno de incidentes (lote, alta exigencia)

Decisión	capaz
Justificación	Cumple el criterio previo: 18/20 aciertos (90 %) contra 13/20 del rápido, es decir 2 errores por cada 20 contra 7, y un error aquí llega al comité sin filtro. Su latencia de 6.3 s es irrelevante en lote. Es una sola corrida por noche: el reporte de 449 tokens cuesta 0.00056 USD de entrada con el capaz, y aun con el costo simulado completo (7.12 USD por 20 casos, 0.356 USD por caso) el gasto diario es marginal frente al costo de un error.
Riesgo residual	La evaluación de 20 casos es de la tarea de campo, no de síntesis de incidentes: el 90 % no está medido para el resumen nocturno. Sigue habiendo 1 de cada 10 resúmenes con un error que el gerente podría llevar al comité.
Mitigación	Antes de producción, evaluar 20 resúmenes reales de incidentes contra un criterio escrito antes (incidente citado con tienda y SKU correctos, sin incidentes inventados). Después, el gerente revisa 2 resúmenes por semana contra el reporte fuente y se registra cada error; si baja de 18/20 en el muestreo mensual, se reabre la decisión.

Control formal del notebook (validar_card): ambas cards con "Compleitud formal: OK".

Salida de la celda-resumen

```
=====
RESUMEN DE RESULTADOS - LAB1-A
=====
```

```
1. Tokens del catálogo:      1580
2. Razón español/inglés:    1.32
3. Score con evidencia en medio: 0.71
4. Aciertos del modelo capaz: 18/20
5. Costo total del rápido:   $1.09
6. Tu decisión para campo:   rapido
=====
```

7. Conclusiones y recomendación de negocio

Conclusión técnica. Para campo, la evidencia decisiva fue la latencia (1.4 s contra 6.3 s frente a una tolerancia de 2.0 s), que descarta al capaz aunque acierte 18/20. Para el resumen nocturno lo decisivo fue la diferencia de aciertos (18/20 contra 13/20), porque ahí la latencia no importa y el error no tiene filtro. Me sorprendieron tres cosas: ningún modelo cumple el criterio de campo; aquí pagar más no sale más barato por resultado (0.396 contra 0.084 USD por acierto); y solo reordenar el contexto vale 19 % de desempeño sin pagar un token más.

Recomendación a la dirección. Usar el modelo rápido como asistente sugerido en campo (alrededor de 54.5 USD al día por 1000 consultas según el costo simulado de la evaluación), vigilando cada semana que llegue a 15 de 20 aciertos, y el modelo capaz para el resumen nocturno (alrededor de 0.36 USD por corrida), validándolo antes con 20 resúmenes reales de incidentes.